ДИПЛОМНЫЙ ПРОЕКТ · SKILLFACTORY

Рекомендательная система для интернет-магазина

Три товара на главной странице: модель, оценка качества и сервис на FastAPI + Docker



3 слота рекомендаций

Датасет Retailrocket · 2015 год

Автор: Роман Емелин

github.com/romanemelin91/Retailrocket-recommender

ЗАДАЧА

Показать три товара, которые человек купит в ближайшие 14 дней

Постановка

- Три слота рекомендаций на главной странице магазина
- Прогноз покупок на следующие 14 дней
- В данных только действия пользователей: просмотр, корзина, покупка (оценок нет)

Цель и метрика

- Цель: рост продаж от персональных рекомендаций
- Метрика: Precision@3, то есть доля угаданных товаров среди трёх рекомендованных
- Дополнительно: Recall@3 и HitRate@3

Пример

Показали 3 товара, человек купил один из них

Precision@3 = 1 / 3 = 0,33

Важная оговорка

Эффект на оборот оффлайн-оценка не измеряет: его проверяют только A/B-тестом.

ДАННЫЕ

В данных 2,76 млн событий, почти все из них просмотры

2,76 млн
событий, с 3 мая по 18 сентября 2015

1,41 млн
пользователей

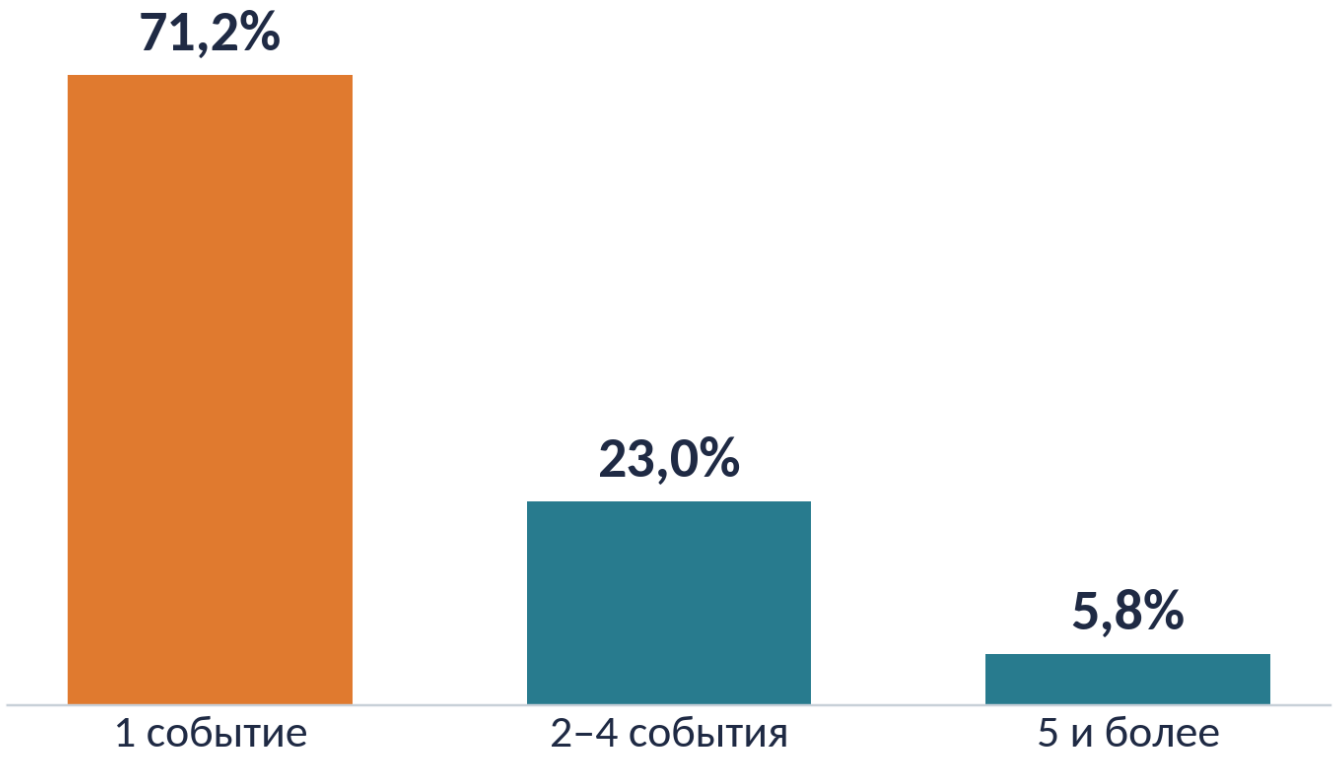
235 тыс.
товаров в событиях

< 1%
покупок (97% просмотры, ≈2,5% корзина)

Файл	Что внутри
events.csv	кто, что и когда делал: просмотр, корзина или покупка (timestamp, visitorid, event, itemid)
category_tree.csv	дерево из 1669 категорий, 25 корневых
item_properties	20,3 млн записей, 1104 свойства; читаемы только categoryid и available, остальные захешированы

> Удалено 460 полных дублей событий; время переведено из миллисекунд в дату (UTC). Пропуски в transactionid и parentid ожидаемы.

У 71% пользователей одно событие: истории почти нет

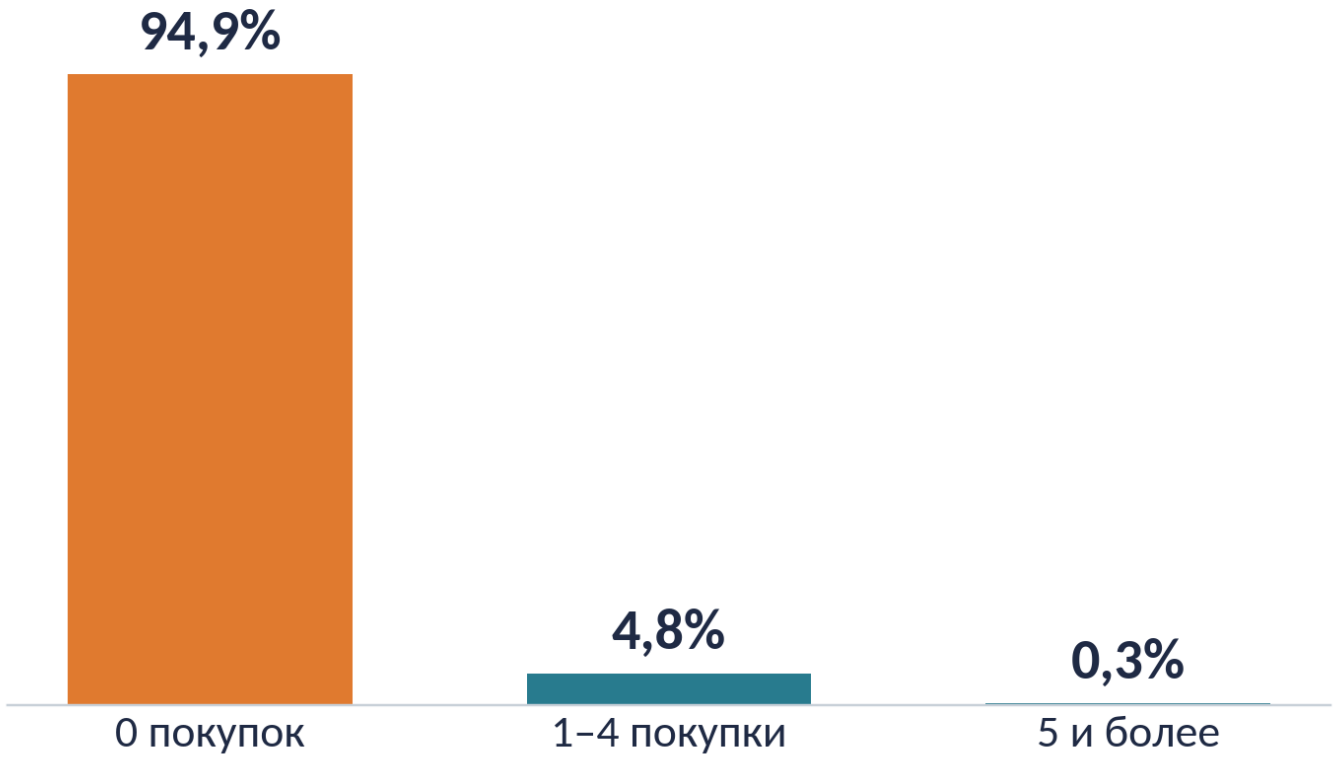


Доля пользователей по числу событий

Что это значит

- 94% пользователей совершили меньше пяти действий
- 83% покупателей на validation новые: персональной истории у них нет (холодный старт)
- Фильтрация малоактивных не помогает: теряется 94% пользователей

94,9% товаров ни разу не покупали: спрос сосредоточен на малой части каталога



Доля товаров по числу покупок

Что это значит

- 665 товаров с пятью и более покупками дают около 25% всех покупок
- Три самых популярных товара покрывают лишь 0,61% покупок следующего периода
- Одинаковые рекомендации для всех почти не работают: нужна персонализация

Проверка устроена по времени: модель не видит будущее



Признаки считаются только по истории до границы, цель: покупки в следующие 14 дней

- Модель выбирается по validation, test считается один раз, после выбора
- Перед test модель доучивается на train + validation
- Утечки проверяются автоматически (assert): события из будущего в признаки не попадают
- Доверительные интервалы (бутстрэп) показывают, где разница настоящая, а где шум

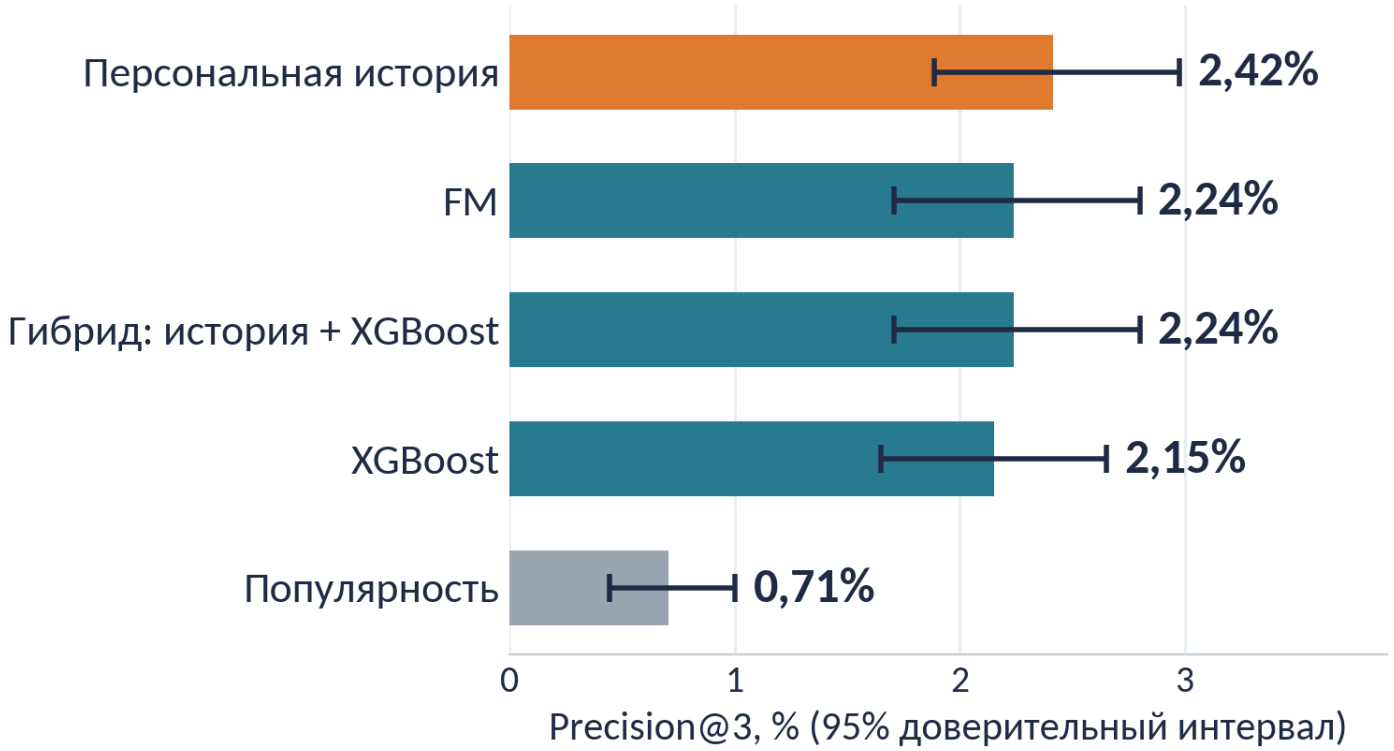
Признаки описывают пользователя, товар и их пару

Группа	Признаки	Как считаются
Пара	просмотры, корзина, покупки; сила интереса; давность последнего события	сила интереса = 1·просмотр + 5·корзина + 15·покупка
Пользователь	активность, число разных товаров, конверсия, давность, просмотры за 7 и 30 дней	счётчики событий; сглаженная конверсия
Товар	просмотры, корзины, покупки, конверсия, доля корзин, давность, покупки за 7 и 30 дней	те же приёмы для товара

Сглаживание
Конверсия сглаживается: (n + α·prior) / (d + α), α = 5. У редких товаров и пользователей она тянется к средней по магазину, без деления на ноль.

Что вошло в итоговую модель
Итоговая модель использует только веса событий. Остальные признаки нужны для экспериментов с XGBoost и FM.

Все модели надёжно лучше популярности, но сложные простую не обогнали



Validation, 1131 покупатель

- Различия между историей, XGBoost и FM в пределах шума: на validation всего около 82 попаданий
- Для новых покупателей (83%) XGBoost, FM и гибрид (0,32–0,36%) не лучше популярности (0,57%)
- Не помогли: другие веса и затухание, фильтрация малоактивных, ItemKNN (0,77%), ALS (1,27%)

ВЫБРАННАЯ МОДЕЛЬ

Простая модель: история пользователя + популярные

1 Оценка интереса

Сумма весов действий по каждому товару: просмотр 1, корзина 5, покупка 15

2 Топ-3 из истории

Три товара пользователя с наибольшей оценкой

3 Добор популярными

Если товаров меньше трёх или пользователь новый, добавляем самые покупаемые

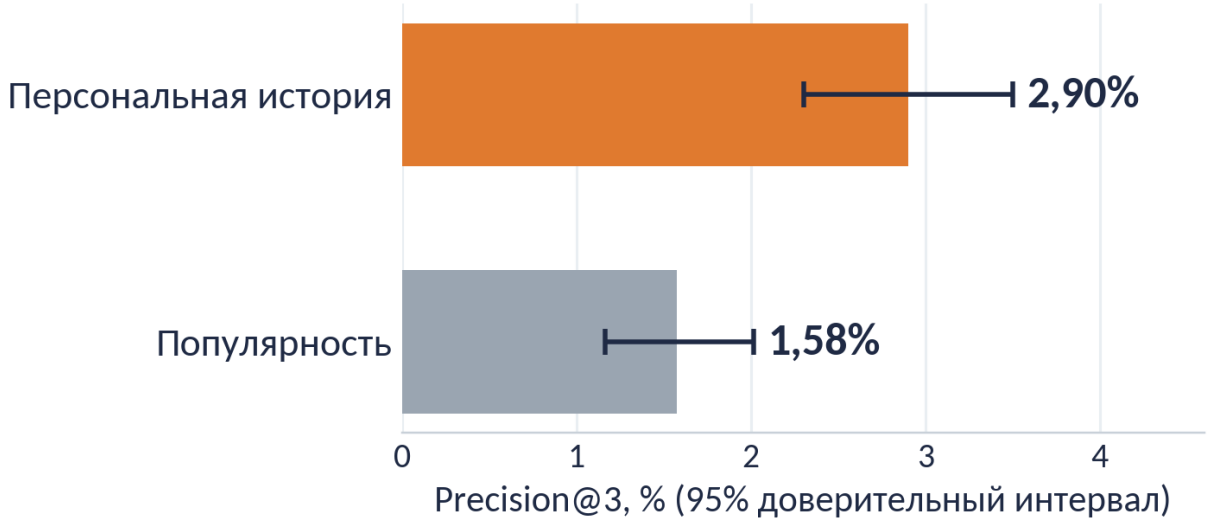
Случай	Что известно	Рекомендации
С историей	товар A (просмотр + покупка = 16), товар B (просмотр = 1)	A, B и популярный товар
Новый пользователь	истории нет	три самых популярных товара

Почему выбрана

Не хуже XGBoost и FM, но проще; в сервисе хранится только словарь «пользователь → три товара», без обученной модели и таблиц признаков.

РЕЗУЛЬТАТ

На тесте точность выросла с 1,6% до 2,9%



+1,3 п.п.

прирост Precision@3 (+84% относительно);
доверительный интервал разности [+0,85; +1,83] п.п.
не содержит нуля

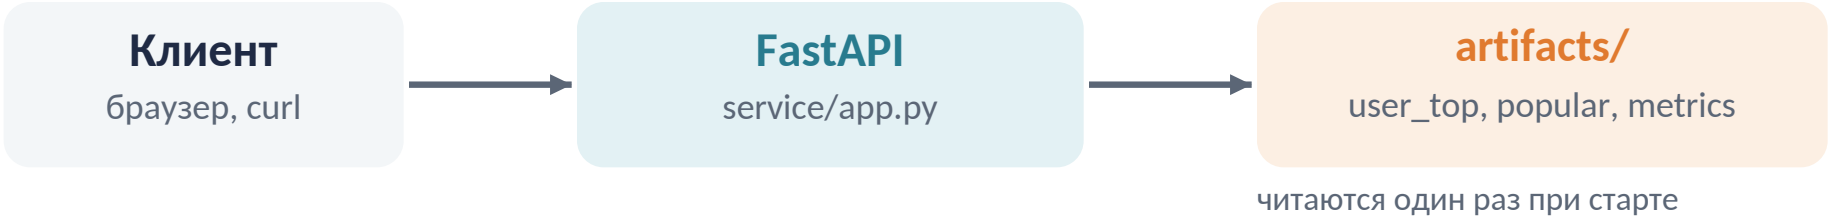
92 против 50

попаданий из 3171 рекомендации

Покупатели test	Precision@3
Известные (199)	9,38%
Новые (858, 81%)	1,40%

Модель обучена на train + validation, 1057 покупателей
Рост оборота не измерялся: 84% относится к Precision@3

Сервис: три запроса и понятная обработка ошибок



Запрос	Ответ
GET /health	состояние сервиса (503, если артефакты не загружены)
GET /metrics	метрики модели из metrics.json
GET /recommend/{id}	три товара и источник: personal или popular

- Неизвестный пользователь получает популярные товары (холодный старт)
- Некорректный id (не число, дробное, отрицательное): ответ 422, сервис не падает
- 8 автотестов; упаковка в Docker (Dockerfile, проверка состояния /health)

Ограничения и что делать дальше

Ограничения

- Покупателей мало (1131 на validation, 1057 на test): разницы меньше 0,5 п.п. не интерпретируются
- 81–83% покупателей новые: им показываем популярное
- Кандидаты «история + 100 популярных» покрывают около 11% покупок
- Нет цены и маржи; оценка оффлайн

Дальше

- A/B-тест: проверить влияние на продажи
- Источники кандидатов для новых пользователей: тренды, категории
- Добавить цену и маржу в цель
- Больше данных и окон проверки для XGBoost и FM

Код, документация и инструкции по запуску:
github.com/romanemelin91/Retailrocket-recommender